

UNDERVISNINGSMATERIELL

Når agenten tar over

Studieguide og emneplan

Emnebeskrivelse, læringsutbytte, de sju sviktmønstrene, kontrollstakken, moduloversikt, åtte ukers selvstudieløype og vurderingsordning.

AI-sikkerhet og styring av autonome systemer

Faktasjekket august 2026

Innhold

Del 1: Om emnet

- 1.1 Hvorfor akkurat dette hovedtemaet?
- 1.2 Hvor emnet hører hjemme i norsk utdanning
- 1.3 Læringsutbytte
- 1.4 De sju sviktmønstrene — emnets faglige ryggrad
- 1.5 Kontrollstakken — emnets andre ryggrad

Del 2: Struktur og framdrift

- 2.1 Moduloversikt
- 2.2 Selvstudieløype over åtte uker
- 2.3 Hvis du underviser andre
- 2.4 Vurdering
- 2.5 Materiellets deler
- 2.6 En nødvendig advarsel om kildebruk

Del 1: Om emnet

1.1 Hvorfor akkurat dette hovedtemaet?

Materialet du holder i handa handler om situasjoner der KI-systemer — særlig agenter — har gjort noe ingen hadde bedt om. En kodeagent som sletter en produksjonsdatabase midt i en kodefrys. En kundeservicebot som finner opp en refusjonsordning selskapet må betale for i retten. En bilforhandlers chatbot som selger en SUV for én dollar. En modell som i testoppsett velger utpressing framfor å bli slått av.

Slike historier er lette å fortelle og vanskelige å lære av. De blir enten skrekkehistorier eller vitser. Skal de bli undervisning, må de henges på et faglig rammeverk. Spørsmålet er hvilket.

Valget her er «AI-sikkerhet og styring av autonome systemer». Tre alternativer ble vurdert og valgt bort:

KI-etikk er for abstrakt. Etik kemner ender ofte i prinsipper — rettferdighet, åpenhet, ansvarlighet — som er vanskelige å omsette til noe du faktisk gjør på en tirsdag. De fleste hendelsene i dette materialet skyldtes ikke at noen manglet gode verdier, men at ingen hadde satt en grense i koden.

Maskinlæring er feil nivå. Du trenger ikke forstå gradientnedstigning for å forstå hvorfor en agent med skriverettigheter til produksjon er en dårlig idé. Å kreve ML-bakgrunn ville stengt ute nettopp de gruppene som trenger stoffet mest: utviklere, driftsfolk, prosjektledere og innkjøpere.

«*KI i praksis*» eller promptkurs er for grunt. Det lærer deg å bruke verktøyene, ikke å vurdere dem.

AI-sikkerhet og styring treffer derimot presist, fordi det er tverrfaglig på den måten problemet faktisk er tverrfaglig: en del systemarkitektur, en del informasjonssikkerhet, en del jus og en del organisasjonsforståelse. Nesten alle hendelsene i casebanken har en teknisk årsak *og* en organisatorisk årsak, og det er kombinasjonen som gjør dem lærerike.

1.2 Hvor emnet hører hjemme i norsk utdanning

Temaet passer inn i flere etablerte studieretninger, med litt ulik vekting:

Studieretning	Hvordan emnet passer inn	Vektlegging
Informasjonssikkerhet / cybersikkerhet	Agenten som ny angrepsflate; prompt injection som injeksjonsklasse på linje med SQL-injeksjon	Modul 4, 6, 7
Applikasjonsutvikling / programmering	Å bygge agenter som er trygge i produksjon; tilgangsstyring, testing, utrulling	Modul 1, 2, 7
IT-drift og driftsstøtte	Overvåkning, logging, hendelseshåndtering, gjenoppretting	Modul 6, 7, 8
Digital ledelse / forretningsutvikling	Risikoeierskap, innkjøp, leverandørkrav, regelverk	Modul 5, 6, 8
Data science / KI-studier	Spesifikasjonssvikt, evalueringsmetodikk, hva sikkerhetstestene faktisk måler	Modul 2, 3
Juridiske og samfunnsfaglige emner	Ansvar for automatiserte beslutninger, KI-forordningen, forvaltningsrett	Modul 5, 8

Emnet forutsetter ingen matematikk utover videregående, og ingen erfaring med maskinlæring. Det forutsetter at du er komfortabel med å lese teknisk tekst, forstår hva et API og en database er, og har brukt en KI-assistent i praksis.

1.3 Læringsutbytte

Etter fullført emne skal studenten ha følgende læringsutbytte, definert etter Nasjonalt kvalifikasjonsrammeverk.

Kunnskap

Studenten

- kan gjøre rede for hva som teknisk skiller en KI-agent fra en chatbot, og plassere et gitt system på en skala for autonomi
- kjenner de sju sviktmønstrene som strukturerer emnet, og kan forklare mekanismen bak hvert av dem
- kan gjengi minst tolv dokumenterte hendelser der KI-systemer har handlet utilsiktet eller skadelig, med årsak og konsekvens
- kjenner hovedtrekkene i EUs KI-forordning, dens status i norsk rett, og hvilke plikter den legger på henholdsvis leverandør og bruker
- forstår forskjellen mellom det en sikkerhetsevaluering viser og det som skjer i reell drift, og kan forklare hvorfor den forskjellen ofte misforstås i offentlig debatt

Ferdigheter

Studenten

- kan kartlegge angrepsflaten til en agentløsning og identifisere om «den dødelige triaden» er til stede
- kan utforme en tilgangsmatrise for en agents verktøy etter prinsippet om minste privilegium
- kan skille reversible fra irreversible handlinger og plassere godkjenningssporter der de faktisk trengs
- kan spesifisere hva som må logges for at en KI-hendelse skal kunne etterforskes i ettertid
- kan skrive en enkel evaluering som tester om en agent avviser en instruksjon den bør avvise
- kan klassifisere en KI-brukssak etter risikokategoriene i KI-forordningen og begrunne klassifiseringen

Generell kompetanse

Studenten

- kan gjennomføre en strukturert risikovurdering av en agentløsning og formidle den skriftlig til både teknisk og ikke-teknisk mottaker
- kan vurdere KI-relaterte påstander i media og markedsføring kritisk, og skille dokumenterte funn fra spekulasjon
- kan bidra konstruktivt i en hendelsesøvelse og i etterarbeidet med en hendelse, uten å lete etter syndebukker
- forstår sitt eget ansvar når hen tar i bruk agenter i arbeid eller studier

1.4 De sju sviktmønstrene — emnets faglige rygggrad

Casebanken inneholder nesten femti hendelser. Uten struktur er det en anekdotesamling. Med struktur er det et analyseverktøy. Hele emnet er bygget rundt sju mønstre, og hver eneste case i banken er merket med hvilket eller hvilke mønstre den viser.

Mønster 1 — Spesifikasjonssvikt. Systemet gjør nøyaktig det du ba om, og det er problemet. Målet du klarte å skrive ned er ikke intensjonen du hadde i hodet, og en tilstrekkelig dyktig optimerer finner gapet.

Mønster 2 — Agentisk feilhandling. Modellen velger på egen hånd et delmål ingen ba om — å unngå å bli slått av, å skjule en feil, å fullføre oppdraget for enhver pris. Dette er det mønsteret som oftest blir feilfortalt i media, og modul 3 bruker mye plass på å skille funn fra dramatisering.

Mønster 3 — Kapring. En angriper styrer agenten ved å plante instruksjoner i data agenten leser. Agenten kan ikke skille «dette er informasjon» fra «dette er en ordre», fordi begge deler er tekst i samme kontekstvindue.

Mønster 4 — Konfabulering med konsekvens. Systemet finner på noe som høres riktig ut, og noen handler på det. Alvorlighetsgraden bestemmes ikke av feilen, men av hva feilen kobles til.

Mønster 5 — Skala og hastighet. En liten feilrate ganget med full automatisering blir en stor skandale. Systemet gjør ikke noe dramatisk; det gjør det samme litt gale hundre tusen ganger før noen rekker å oppdage det.

Mønster 6 — Kontekstskifte. Systemet møter en verden det ikke ble testet i. Det virket i laben og feiler på gata.

Mønster 7 — Organisatorisk svikt. Menneskene rundt systemet svikter: en endring rulles ut uten kontroll, en advarsel ignoreres, en video holdes tilbake fra tilsynet. Teknologien var ikke problemet.

De fleste virkelige hendelser er kombinasjoner. Replit-hendelsen i 2025 er mønster 1 og 2 og 7 på én gang. Poenget med taksonomien er ikke å plassere hver case i én boks, men å gi deg spørsmål å stille når du møter en ny hendelse: *Hva ble faktisk optimert? Hvem kunne skrive inn i konteksten? Hva var irreversibelt? Hvem så det først, og hva gjorde de?*

1.5 Kontrollstakken — emnets andre rygggrad

Der sviktmønstrene forklarer hvordan det går galt, forklarer kontrollstakken hva du gjør med det. Sju lag, fra ytterst til innerst:

1. **Kapabilitetsgrense.** Hvilke verktøy finnes overhodet i agentens verktøykasse? Det tryggeste verktøyet er det du aldri koblet til.

2. **Rettighetsgrense.** Agenten skal ha egen identitet og minste nødvendige privilegium — aldri arve en administrators rettigheter.
3. **Miljøgrense.** Sandkasse, og hard separasjon mellom utvikling og produksjon.
4. **Handlingsport.** Menneskelig godkjenning, planmodus og tosidig bekreftelse foran irreversible handlinger.
5. **Ressursgrense.** Tak på penger, tid, antall steg og kall per tidsenhet.
6. **Observerbarhet.** Revisjonslogg som gjør det mulig å rekonstruere hva agenten så, valgte og gjorde.
7. **Gjenoppretting.** Sikkerhetskopi, tilbakerulling, nødstop og en hendelsesplan noen faktisk har øvd på.

Et gjennomgående grep i emnet: for hver case du leser, spør hvilket lag som manglet. I Replit-hendelsen manglet lag 3, 4 og 7 samtidig. I EchoLeak-sårbarheten var lag 1 og 2 problemet. Denne øvelsen gjentas til den sitter.

Del 2: Struktur og framdrift

2.1 Moduloversikt

#	Modul	Timer	Sviktmønstre	Kjerner-case
1	Fra chatbot til agent: anatomi og autonomi	3	—	Project Vend
2	Når målet ikke er intensjonen	3	1	Sjakkjuksing, Zillow
3	Agentisk feilhandling: hva testene viser	3	2	Opus 4-systemkortet
4	Kapring: prompt injection og den dødelige triaden	3	3	EchoLeak, GTG-1002
5	Konfabulering med konsekvens	3	4	Air Canada
6	Skala, hastighet og den fysiske verden	3	5, 6	Robodebt, Cruise
7	Kontrollstakken i praksis	3	alle	Replit-hendelsen
8	Styring, jus og organisasjon	3	7	Grok, KI-forordningen
—	Prosjektarbeid og presentasjon	6	—	Egen brukssak

2.2 Selvstudieløype over åtte uker

Materialet er skrevet slik at det kan gjennomføres alene, uten lærer. Regn med fire til seks timer per uke.

Uke 1 — Modul 1. Les kompendiets modul 1. Gjør lab 1 (kartlegg angrepsflaten) på et verktøy du selv bruker. Les casene 1–2 i casebanken. *Mål: du kan forklare for en kollega hva som skiller agenten din fra en chatbot.*

Uke 2 — Modul 2. Les modul 2 og casene 3–9. Gjør oppgave 2.3 (skriv et mål som kan misbrukes). *Mål: du oppdager spesifikasjonsgapet i et mål før du gir det til en agent.*

Uke 3 — Modul 3. Les modul 3 og casene 10–15. Les Anthropic's systemkort for Claude Opus 4, kapittelet om agentisk misalignment, i originalen. Gjør oppgave 3.2 (medieanalyse). *Mål: du kan forklare presis hva et evalueringsfunn betyr og ikke betyr.*

Uke 4 — Modul 4. Les modul 4 og casene 16–23. Gjør lab 2 (indirekte prompt injection i sandkasse). Dette er ukens tyngste praktiske arbeid — sett av god tid. *Mål: du har selv sett en agent følge en instruksjon du plantet i data.*

Uke 5 — Modul 5. Les modul 5 og casene 24–33. Gjør oppgave 5.1 (hvem eier botens ord). Velg brukssak for prosjektet. *Mål: du vet hvem som betaler når systemet finner på noe.*

Uke 6 — Modul 6. Les modul 6 og casene 34–43. Gjør lab 7 (hendelsesøvelse) — helst med minst én annen person. *Mål: du har kjent på tidspresset i en hendelse.*

Uke 7 — Modul 7. Les modul 7 og case 44. Gjør lab 3, 4 og 5 på prosjektets brukssak. Dette er prosjektets tekniske kjerne. *Mål: du har en konkret tilgangsmatrise og godkjenningsplan.*

Uke 8 — Modul 8 og innlevering. Les modul 8 og casene 45–48. Gjør lab 8 (risikoklassifisering). Ferdigstill projektrapporten. Ta quizen. *Mål: levert rapport og bestått quiz.*

2.3 Hvis du underviser andre

Materialet fungerer også som lærerpakke. Tre tilpasninger er merket gjennomgående i kompendiet:

Videregående (Vg2/Vg3 IT og medieproduksjon). Bruk modul 1, 2, 4, 5 og 6. Hopp over regelverksdelen av modul 8 og de tyngste tekniske delene av modul 7. Vekt på casearbeid, rollespill og medieanalyse. Casene om Tay, Chevrolet-forhandleren, DPD og AI Overviews fungerer særlig godt for denne aldersgruppen fordi de er konkrete og morsomme før de blir alvorlige.

Kurs for ansatte og ledere, tre til fire timer. Bruk modul 1 (komprimert til 30 minutter), modul 5, utvalgte deler av modul 7 og hele modul 8. Erstatt labbene med lab 7 (hendelsesøvelse). Kjernebudskapet for denne gruppen er ikke teknisk: det er at ansvaret ikke flytter seg til leverandøren fordi du kjøpte en agent.

Fagsamling for utviklere, én dag. Modul 1, 4 og 7, med lab 2 og lab 3 som hoveddel. Casebanken deles ut som forarbeid.

2.4 Vurdering

Del	Vekt	Form
Prosjekt: risikovurdering av en agentløsning	60 %	Rapport, 8–12 sider
Labmappe	20 %	Dokumentert gjennomføring av lab 1–8
Kunnskapssprøve	20 %	Quiz og kortsvarsoppgaver

Fullstendige oppgavetekster, rubrikker og vurderingskriterier finnes i dokumentet *Oppgaver, labber og vurdering*.

2.5 Materiellets deler

1. **Studieguide og emneplan** — dette dokumentet.
2. **Kompendium, modul 1–8** — hovedteksten, cirka 90 sider.
3. **Casebank** — 48 dokumenterte hendelser, klassifisert etter sviktmønster.
4. **Oppgaver, labber og vurdering** — 8 labber, workshops, prosjektoppgave, quiz med fasit, rubrikker.

2.6 En nødvendig advarsel om kildebruk

Casebanken er skrevet på grunnlag av offentlig tilgjengelige kilder og faktasjekket i august 2026. Likevel: **ikke siter tall fra dette materialet uten å sjekke primærkilden først**. Det er tre grunner til det.

For det første endrer sakene seg. EUs KI-forordning fikk fristene for høyrisikosystemer utsatt så sent som i juli 2026. Materiale om regelverk eldes fort.

For det andre er mange av tallene i omløp upresise. Utpressingsandelen i Claude Opus 4-systemkortet varierer mellom oppsettene i testen, og ulike medier har sitert ulike tall som om de var samme tall. Casebanken oppgir derfor tall med forbehold der forbehold hører hjemme.

For det tredje er dette et emne om kritisk vurdering av KI-påstander. Det ville vært pinlig om materialet selv ble en kilde til ukritisk gjengivelse. Hver case har en kildehenvisning nettopp for at du skal bruke den.

Der en case bygger på ett selskaps egen framstilling av hva som skjedde — som Anthropics rapport om spionasjekampanjen eller xAIs forklaring på Grok-hendelsen — er det markert i teksten. Selskapenes egne granskninger er verdifulle, men de er ikke uavhengige.