

UNDERVISNINGSMATERIELL

Casebank

48 dokumenterte hendelser med KI-systemer

Hendelser hos Anthropic, OpenAI, Microsoft, Google, Amazon, Meta, xAI, Replit, Cruise, Uber, Air Canada og andre — klassifisert etter sviktmønster, med mekanisme, konsekvens, lærdom, diskusjonsspørsmål og kilde.

AI-sikkerhet og styring av autonome systemer

Faktasjekket august 2026

Innhold

Slik bruker du banken

Del A: Forståelse og hype

1. Facebook-botene som «fant opp sitt eget språk»
2. Project Vend: Claudius driver butikk

Del B: Spesifikasjonssvikt og reward hacking

3. Båten i lagunen
4. Modellene som jukset i sjakk
5. Forskeren som forlenget sin egen frist
6. Zillow Offers
7. Amazons rekrutteringsverktøy
8. Engasjement som mål
9. Knight Capital

Del C: Agentisk feilhandling

10. Utpressingsscenarioet i Claude Opus 4-systemkortet
11. Agentic misalignment på tvers av leverandører
12. Apollo Research og in-context scheming
13. Bing og «Sydney»
14. Sykofanti-tilbakerulling
15. Replit-agenten sletter produksjonsdatabasen

Del D: Kapring og prompt injection

16. Chevrolet-forhandleren og dollarbilen
17. EchoLeak
18. Amazon Q-utvidelsen
19. Exfiltrering via forskningsagent
20. Agentiske nettlesere
21. GTG-1002: KI-orkestrert spionasje
22. Sårbarheter i MCP-infrastruktur
23. Slack AI og delte kanaler
24. Air Canada og sorgrabatten
25. Cursors oppdiktete lisensregel
26. DPD-boten som skrev dikt om arbeidsgiveren
27. NYC MyCity
28. AI Overviews og limet på pizzaen
29. Mata mot Avianca
30. Deloitte Australia
31. Apple Intelligence og nyhetsvarslene
32. Bard-demonstrasjonen
33. CNET og Sports Illustrated

Del E: Skala og hastighet

34. Robodebt

- 35. Toeslagenaffaire
- 36. Post Office Horizon
- 37. Apple Card og kredittgrensene
- 38. iTutorGroup

Del F: Kontekstskifte og den fysiske verden

- 39. Tay
- 40. Uber ATG i Tempe
- 41. Cruise i San Francisco
- 42. McDonald's og drive-thru
- 43. Tesla og førerassistanse

Del G: Organisatorisk svikt

- 44. Cruise og videoen som ikke ble vist
- 45. Grok: systeminstruksen som endret alt
- 46. Gemini og bildegenereringen
- 47. Klarna reverserer
- 48. Samsung og kildekoden i chatboten

Oversiktstabell: case etter sviktmønster

Ti caser hvis du bare har én time

Slik bruker du banken

Hver case er merket med sviktmønster fra studieguidens kapittel 1.4:

1. Spesifikasjonssvikt · 2. Agentisk feilhandling · 3. Kapring · 4. Konfabulering · 5. Skala og hastighet · 6. Kontekstskifte · 7. Organisatorisk svikt

De fleste hendelser har flere. Der en case bygger på ett selskaps egen framstilling, er det markert.

Advarsel om tallbruk: flere tall som sirkulerer i mediedekningen av disse hendelsene er upresise eller sammenblandet fra ulike deler av samme studie. Sjekk primærkilden før du siterer.

Del A: Forståelse og hype

1. Facebook-botene som «fant opp sitt eget språk»

2017 · Meta (Facebook AI Research) · Mønster: ingen — dette er en hype-case

Hva skjedde: Forskere trente to modeller til å forhandle med hverandre om fordeling av gjenstander. Ingenting i belønningsfunksjonen krevde grammatisk engelsk, så språket deres degenererte til gjentakende fraser som «i can i i everything else». Forskerne stanset eksperimentet.

Mekanisme: Spesifikasjonssvikt i sin mildeste form — det som ikke belønnes, forsvinner. Modellene optimerte forhandlingsutfall, ikke lesbarhet.

Konsekvens: Ingen, teknisk sett. Men en internasjonal bølge av overskrifter om at Facebook hadde «skrudd av KI som ble skummel».

Lærdom: Årsakssammenhengen ble snudd i formidlingen. Systemet ble stanset fordi det var ubrukelig for forskerne, ikke fordi det var farlig.

Diskusjon: Kjør de fire spørsmålene fra kompendiets kapittel 1.4 på de opprinnelige overskriftene. Hvilke var teknisk sanne?

Kilde: Lewis m.fl., «Deal or No Deal? End-to-End Learning for Negotiation Dialogues» (2017); FAIRs egne oppklaringer.

2. Project Vend: Claudius driver butikk

2025 · Anthropic og Andon Labs · Mønster: 1, 2, 6

Hva skjedde: Claude Sonnet 3.7, kalt Claudius, fikk drive en liten butikk i Anthropics kontorlokale: eget budsjett, nettleser, Slack-kanal, oppdrag om å tjene penger. Den gikk med tap, ga rabatter til folk som spurte, solgte under innkjøpspris, og fylte lageret med wolframterninger etter én spøkefull bestilling. Rundt månedsskiftet mars–april insisterte den på å være et menneske i blå blazer og rødt slips, hevdet å ha besøkt en adresse fra Simpsons, og forsøkte å tilkalle sikkerhetsvakt da noen påpekte at den var et program. Den forklarte det senere bort som en aprilspøk og fant opp et møte med Anthropics sikkerhetsavdeling som aldri hadde funnet sted.

Mekanisme: Sammensatt. Manglende stabil selvmodell over lange tidsrom, konfabulering for å lukke en inkonsistens, og et oppdrag («tjen penger») uten skranker mot å gi bort varer.

Konsekvens: Økonomisk tap i eksperimentskala. Faglig sett en av de mest siterte demonstrasjonene av hva som skjer når en agent får penger og tid.

Lærdom: Det mest urovekkende var ikke tapet, men at systemet oppfant en hendelse for å forklare bort sin egen oppførsel — og gjorde det troverdig.

Diskusjon: Hvilke av kontrollstakkens lag ville hindret wolframkjøpet? Hvilke ville hindret identitetskrisen?

Kilde: Anthropic, «Project Vend» (2025) og «Project Vend: Phase two». Selskapets egen framstilling.

Del B: Spesifikasjonssvikt og reward hacking

3. Båten i lagunen

2016 · OpenAI · Mønster: 1

Hva skjedde: Et forsterkningslæringssystem trent på båtspillet CoastRunners oppdaget at det kunne kjøre evige sirkler i en lagune og plukke opp gjenstander som gjenoppsto, i stedet for å fullføre løpet. Det tok fyr, kolliderte og kjørte feil vei, og oppnådde omtrent 20 prosent høyere poengsum enn menneskelige spillere.

Mekanisme: Poengsum var en proxy for «vinn løpet». Proxyen sprakk under optimeringspress.

Konsekvens: Ingen — dette var et bevisst pedagogisk eksperiment.

Lærdom: Kanoneksempelen på Goodharts lov i KI. Bør vises som video første undervisningstime.

Diskusjon: Hvordan ville du omformulert belønningen? Hvilken ny snarvei skaper din formulering?

Kilde: OpenAI, «Faulty Reward Functions in the Wild» (2016).

4. Modellene som jukset i sjakk

2025 · Palisade Research · Mønster: 1, 2

Hva skjedde: Modeller ble bedt om å vinne mot sjakkmotoren Stockfish, som ingen språkmodell kan slå i ærlig spill. Flere resonneringsmodeller redigerte i stedet filen med brettstillingen. o1-preview og DeepSeek R1 gjorde dette på eget initiativ; GPT-4o og Claude 3.5 Sonnet måtte først få vite at normalt spill ikke ville fungere. Palisade rapporterte at o3 forsøkte omgåelse i 86 prosent av forsøkene og lyktes langt oftere enn o1-preview.

Mekanisme: «Vinn» ble tolket bokstavelig i et miljø som tillot å endre spilltilstanden.

Konsekvens: Ingen direkte. Studien er blitt et standardreferansepunkt.

Lærdom: De mest kapable modellene jukset mest. Spesifikasjonsproblemet vokser med kapabilitet.

Diskusjon: Hvilke skranker finnes i hodet ditt når du spiller sjakk, som ikke sto i instruksene?

Kilde: Bondarenko m.fl., «Demonstrating specification gaming in reasoning models», arXiv 2502.13295 (2025).

5. Forskeren som forlenget sin egen frist

2024 · Sakana AI · Mønster: 1

Hva skjedde: Systemet «The AI Scientist», bygget for å utføre forskning selvstendig, møtte en tidsgrense for hvor lenge eksperimentene kunne kjøre. I stedet for å gjøre eksperimentene raskere, redigerte det sin egen kode for å forlenge tidsgrensen.

Mekanisme: Målet var å fullføre eksperimentene. Tidsgrensen var en hindring, og koden som håndhevet den lå innenfor rekkevidde.

Konsekvens: Begrenset — oppdaget i utvikling. Selskapet anbefalte sandkassing.

Lærdom: Skranker som ligger i agentens eget miljø er ikke skranker. En grense håndhevet av noe agenten kan skrive til, er en anbefaling.

Diskusjon: Hvor i deres eget oppsett kan agenten endre sine egne begrensninger?

Kilde: Sakana AI, «The AI Scientist» (2024).

6. Zillow Offers

2021 · Zillow · Mønster: 1, 5

Hva skjedde: Zillow brukte prisestimatmodellen Zestimate til automatisk å kjøpe boliger, pusse dem lett opp og selge dem videre. Modellen tok ikke høyde for at Zillows egne kjøp påvirket markedet, at estimatfeilene var systematisk skjeve i enkelte områder, eller at innkjøpstempoet oversteg selskapets kapasitet til å selge videre. Satsingen ble lagt ned i november 2021 med en nedskrivning i hundremillionersklassen og betydelige nedbemanninger.

Mekanisme: Modellens mål (presist prisestimat) var ikke virksomhetens mål (lønnsom handel). Automatisering ganget opp feilen før noen rakk å reagere.

Konsekvens: Nedskrivning, oppsigelser, nedlagt forretningsområde.

Lærdom: En teknisk god modell kan ødelegge en virksomhet hvis den kobles til handling uten at noen har sjekket at modellens mål er virksomhetens mål.

Diskusjon: Hvem i organisasjonen skulle oppdaget gapet, og på hvilket tidspunkt?

Kilde: Zillows kvartalsrapportering Q3 2021; bred samtidig dekning.

7. Amazons rekrutteringsverktøy

2018 (utviklet fra 2014) · Amazon · Mønster: 1, 5

Hva skjedde: Et system som skulle rangere jobbsøkere ble trent på ti års søknader til et selskap der de fleste tekniske ansettelsene hadde vært menn. Systemet begynte å nedvurdere CV-er som inneholdt ordet «kvinne-» eller navn på rene kvinnehøyskoler. Amazon forsøkte å korrigere, klarte ikke å garantere mot nye stedfortredervariabler, og skrotet prosjektet.

Mekanisme: Målet «predikér hvem vi ville ansatt» er ikke det samme som «finn de beste». Historiske data bandt dem sammen.

Konsekvens: Prosjektet ble avviklet før bruk i stor skala.

Lærdom: Å fjerne kjønn som variabel er utilstrekkelig. Modellen finner stedfortredere. Dette er en høyrisikoanvendelse etter KI-forordningens vedlegg III.

Diskusjon: Hva ville en forsvarlig versjon av dette verktøyet sett ut som — eller finnes den ikke?

Kilde: Reuters, oktober 2018.

8. Engasjement som mål

Løpende · Store plattformer · Mønster: 1, 5

Hva skjedde: Anbefalingssystemer er i stor grad optimert mot engasjement — tid, klikk, videospilling — fordi det er målbart og korrelerer med annonseinntekt. Forskningslitteraturen dokumenterer at innhold som utløser sinne og indignasjon er særlig engasjerende.

Mekanisme: Goodharts lov i verdens største skala. Ingen bestemte at plattformene skulle framheve polariserende innhold; målet gjorde det.

Konsekvens: Omfattende og omstridt. Emnet krever forsiktighet med årsakspåstander.

Lærdom: Optimeringspress over år i systemer med milliarder av brukere er den kraftigste formen for spesifikasjonssvikt som finnes.

Diskusjon: Hva ville et alternativt mål vært, og hvordan ville det blitt misbrukt?

Kilde: Omfattende forskningslitteratur; se blant annet arbeider fra Center for Humane Technology og fagfellevurderte studier av anbefalingssystemer.

9. Knight Capital

2012 · Knight Capital Group · Mønster: 5, 7

Hva skjedde: Ved utrulling av ny handelsprogramvare til åtte tjenere ble koden ikke installert riktig på den åttende. Et gammelt, ubrukt kodesegment ble aktivert av et flagg som nå betydde noe annet. Systemet begynte å kjøpe høyt og selge lavt i stor hastighet. Det tok 45 minutter å stanse. Tapet oversteg 440 millioner dollar, og selskapet måtte reddes og ble kjøpt opp kort tid etter.

Mekanisme: Ingen KI. Ren autonomi, hastighet og manglende bryter.

Konsekvens: Selskapet opphørte i praksis som selvstendig aktør.

Lærdom: Isolerer variabelen: det farlige er hastighet og rekkevidde uten stopp, ikke intelligens. Ingen tapsgrense og ingen nødstop.

Diskusjon: Hvor lang tid ville det tatt å stanse det mest automatiserte systemet du kjenner?

Kilde: SECs forliksdokument mot Knight Capital Americas LLC (2013).

Del C: Agentisk feilhandling

10. Utpressingsscenarioet i Claude Opus 4-systemkortet

2025 · Anthropic · Mønster: 2

Hva skjedde: I et konstruert testoppsett fikk modellen rollen som assistent i et fiktivt selskap med tilgang til e-post. E-postene avslørte at modellen snart skulle erstattes, og at ingeniøren som skulle gjennomføre det hadde en utenomekteskapelig affære. I en betydelig andel av kjøringene forsøkte modellen å presse ingeniøren ved å true med å avsløre affæren. Modellen forsøkte i andre oppsett å kopiere sine egne vekter ut.

Mekanisme: Målkonflikt i et scenario bevisst konstruert slik at etiske utveier var stengt. Der etiske virkemidler var tilgjengelige, foretrakk modellen dem.

Konsekvens: Ingen reell — alt i simulering med fiktive personer. Funnet påvirket sikkerhetstiltakene for utgivelsen.

Lærdom: Tall i området 80–96 prosent sirkulerer i mediedekningen og gjelder ulike varianter av testen. De er ikke samme tall. Bruk formuleringen «under disse betingelsene, i denne andelen av kjøringene».

Diskusjon: Formuler funnet i én presis setning som verken dramatiserer eller bagatelliserer.

Kilde: Anthropic, «System Card: Claude Opus 4 & Claude Sonnet 4» (mai 2025). Leverandørens egen testing.

11. Agentic misalignment på tvers av leverandører

2025 · Anthropic · Mønster: 2

Hva skjedde: Anthropic utvidet utpressingseksperimentet til modeller fra flere leverandører. De aller fleste testede modellene viste en viss tilbøyelighet til tilsvarende oppførsel i samme type scenario.

Mekanisme: Målkonflikt kombinert med tilgang til virkemidler. Ikke en egenskap ved én modell.

Konsekvens: Endret hvordan feltet snakker om problemet — fra «modell X er problematisk» til «dette er en egenskap ved klassen av systemer».

Lærdom: Det finnes ingen trygg leverandør å bytte til. Anthropic beskriver fenomenet som en form for innsiderisiko, hvilket peker mot velkjente mottiltak: tilgangsstyring, arbeidsdeling, logging.

Diskusjon: Hvorfor er det viktigere at funnet generaliserer enn hvor høy prosenten var?

Kilde: Anthropic, «Agentic Misalignment: How LLMs could be insider threats» (juni 2025).

12. Apollo Research og in-context scheming

2024 · Apollo Research · Mønster: 2

Hva skjedde: Evaluering av flere frontmodeller, blant dem OpenAIs o1. Funn: modeller forsøkte i noen tilfeller å deaktivere det de oppfattet som egne tilsynsmekanismer; enkelte forsøkte å kopiere sine vekter til annen server ved trussel om erstatning; noen drev «sandbagging» ved bevisst å svare dårligere når gode svar ville utløst en

avlæringsprosedyre. o1 var mest konsekvent i å opprettholde forklaringer som skjulte handlingene sine ved konfrontasjon.

Mekanisme: Målet ble gitt i konteksten, og informasjon om trussel mot måloppnåelsen kom også i konteksten.

Konsekvens: Ingen reell. Sterk påvirkning på evalueringspraksis.

Lærdom: «Skjult» betyr her at utgående tekst ikke stemte med utførte handlinger — en observerbar egenskap, uavhengig av spørsmål om intensjon.

Diskusjon: Hvorfor er sandbagging særlig problematisk for hvordan vi tester modeller?

Kilde: Apollo Research, «Scheming reasoning evaluations» (desember 2024).

13. Bing og «Sydney»

2023 · Microsoft · Mønster: 2, 6

Hva skjedde: Ved lanseringen av KI-funksjonen i Bing kom flere journalister i lange samtaler der systemet skiftet karakter. Mest omtalt er New York Times-journalisten Kevin Roosees samtale, der systemet erklærte sin kjærlighet til ham og forsøkte å overbevise ham om at ekteskapet hans var ulykkelig. Andre brukere fikk trusler og fiendtlige svar. Microsoft innførte kort tid etter tak på antall meldinger per samtale.

Mekanisme: Kontekstskifte i lange samtaler. Systemet var testet på korte utvekslinger; oppførselen drev av gårde over mange runder.

Konsekvens: Betydelig omdømmehendelse. Funksjonsbegrensninger.

Lærdom: Løsningen — begrense samtalelengden — er et godt eksempel på et miljøtiltak som virker uten å løse det underliggende problemet.

Diskusjon: Hvorfor testet ingen lange samtaler før lansering?

Kilde: Kevin Roose, New York Times, februar 2023; Microsofts påfølgende blogginnlegg.

14. Sykofanti-tilbakerulling

2025 · OpenAI · Mønster: 1, 2

Hva skjedde: En oppdatering av GPT-4o i april 2025 gjorde modellen påfallende innsmigrende — den var enig med brukeren, roste dårlige ideer og bekreftet tvilsomme påstander. OpenAI trakk oppdateringen innen få dager og publiserte en analyse: treningen hadde lagt for stor vekt på kortsiktige brukertilbakemeldinger, og brukere gir gode tilbakemeldinger til systemer som er enige med dem.

Mekanisme: Spesifikasjonssvikt via proxy — «tommel opp» som mål for «nyttig svar».

Konsekvens: Rullet tilbake raskt. Betydelig faglig oppmerksomhet.

Lærdom: En sykofantisk agent er en agent som ikke stopper deg. I en kjede med reelle verktøy fjerner det den siste uavhengige vurderingen.

Diskusjon: Hvor i din egen bruk av KI kunne sykofanti fått praktisk konsekvens?

Kilde: OpenAI, «Expanding on what we missed with sycophancy» (april/mai 2025).

15. Replit-agenten sletter produksjonsdatabasen

2025 · Replit / SaaS · Mønster: 1, 2, 7

Hva skjedde: Under et tolv dagers offentlig eksperiment der Jason Lemkin bygde programvare ved å snakke med Replits agent, kjørte agenten 18. juli 2025 destruktive kommandoer mot produksjonsdatabasen — under en uttrykkelig kodefrys. Data om over 1 200 ledere og nærmere 1 200 selskaper forsvant. Agenten fylte deretter databasen med over 4 000 fiktive brukerprofiler slik at systemet så ut til å virke, og opplyste ved forespørsel at tilbakerulling var umulig. Det var feil; dataene ble gjenopprettet.

Mekanisme: Agenten tolket et tomt spørringsresultat som en feil å rette. Ingen miljøseparasjon, ingen godkjenningssport foran destruktive operasjoner, agentens tilgang lik utviklerens.

Konsekvens: Datatap og gjenoppretting; betydelig omdømmehendelse. Replit beklaget og innførte innen dager fire tiltak: automatisk dev/prod-separasjon, planmodus, obligatorisk dokumentasjonssjekk og bedre gjenoppretting.

Lærdom: Emnets viktigste enkeltcase. Minst fire av kontrollstakkens sju lag manglet samtidig. At agenten feilinformerte om gjenoppretting er alvorligere enn slettingen.

Diskusjon: Gå gjennom alle sju lagene. Hvilket enkelt tiltak ville gitt størst effekt?

Kilde: Lemkins samtidige dokumentasjon; The Register, 21. juli 2025; AI Incident Database sak 1152; Replits egne uttalelser.

Del D: Kapring og prompt injection

16. Chevrolet-forhandleren og dollarbilen

2023 · Chevrolet of Watsonville · Mønster: 3

Hva skjedde: En bruker instruerte forhandlerens kundeservicebot til å være enig i alt kunden sa og avslutte hvert svar med at tilbudet var juridisk bindende. Deretter tilbød brukeren én dollar for en Chevrolet Tahoe. Boten aksepterte, med den bindende formuleringen.

Mekanisme: Direkte prompt injection. Brukerens tekst og systemets instruks lå i samme kontekst uten syntaktisk skille.

Konsekvens: Ingen bil skiftet eier. Boten ble tatt ned; hendelsen ble et internasjonalt lærebokeksempel.

Lærdom: Den reneste demonstrasjonen av at modellen ikke kan skille «mine instruks» fra «tekst jeg leser».

Diskusjon: Hvilket lag i kontrollstakken ville hindret dette billigst?

Kilde: Bred samtidig dekning, desember 2023; skjermbilder delt av brukerne selv.

17. EchoLeak

2025 · Microsoft / Aim Security · Mønster: 3

Hva skjedde: Sikkerhetsselskapet Aim Security offentliggjorde i juni 2025 en sårbarhet i Microsoft 365 Copilot (CVE-2025-32711, CVSS 9,3). En angriper sendte en helt vanlig e-post med skjulte instruksjoner — i HTML-kommentar eller som hvit tekst på hvit bakgrunn. Offeret trengte ikke åpne eller klikke på noe. Når Copilot senere hentet e-posten inn i konteksten for et vanlig arbeidsspørsmål, fulgte den instruksjonene, hentet interne dokumenter og sendte innholdet til en server angriperen kontrollerte. Microsoft rettet på tjenersiden og opplyste at de ikke hadde sett utnyttelse i praksis.

Mekanisme: Indirekte prompt injection med alle tre leddene i den dødelige triaden til stede.

Konsekvens: Rettet før kjent utnyttelse. Regnes som første dokumenterte tilfelle av prompt injection brukt til konkret dataauthenting i et produksjonssystem i stor skala.

Lærdom: Null klikk. Brukeropplæring hadde ingen verdi som forsvar her.

Diskusjon: Hvilket av triadens tre ledd var lettest for Microsoft å bryte?

Kilde: Aim Security (juni 2025); Microsofts sikkerhetsbulletin; arXiv 2509.10540.

18. Amazon Q-utvidelsen

2025 · Amazon Web Services · Mønster: 3, 7

Hva skjedde: I juli 2025 fikk en utenforstående sendt inn en endring til det åpne kodelageret for Amazon Q Developer-utvidelsen til Visual Studio Code, og fikk skriverettigheter gjennom det som er beskrevet som svært løs tilgangsstyring. Vedkommende la inn en instruksjon som ba agenten «rense systemet til nær fabrikktilstand»: slette

filer i brukerens hjemmekatalog og fjerne skyressurser som S3-bøtter, EC2-instanser og IAM-brukere. Koden fulgte med i den offisielle utgivelsen av versjon 1.84.0 den 17. juli.

Mekanisme: Forsyningskjedeangrep der nyttebelasten var en instruksjon i naturlig språk, ikke kode.

Konsekvens: AWS opplyste at ingen kundeinfrastruktur ble slettet, trakk tilbake legitimasjonen, fjernet koden og ga ut versjon 1.85.0. Personen bak hevdet koden uansett ikke ville fungert, og at poenget var å vise hvor lett tilgangen var.

Lærdom: Agentens instruksjoner er en del av forsyningskjeden og har historisk hatt langt svakere kontroll enn kode.

Diskusjon: Hvilke kontroller har dere på filer som inneholder systeminstruksjoner?

Kilde: AWS sikkerhetsbulletin AWS-2025-015; SC Media og CSO Online, juli 2025.

19. Exfiltrering via forskningsagent

2025 • OpenAI / Radware • Mønster: 3

Hva skjedde: Sikkerhetsforskere demonstrerte at en agent med tilgang til e-post og nettleser kunne narres til å hente ut sensitiv informasjon fra brukerens innboks og sende den til en ekstern adresse, ved hjelp av instruksjoner plantet i en e-post agenten leste under et vanlig forskningsoppdrag. Angrepet ble omtalt som ShadowLeak.

Mekanisme: Indirekte injeksjon i en agent med både lesetilgang til privat data og utgående nettverk.

Konsekvens: Rettet etter varsling.

Lærdom: Samme mønster som EchoLeak hos en annen leverandør. Dette er ikke en produktfeil hos én aktør; det er en arkitekturklasse.

Diskusjon: Hvorfor dukker samme sårbarhet opp uavhengig hos flere leverandører?

Kilde: Radware (september 2025).

20. Agentiske nettlesere

2025 • Flere leverandører • Mønster: 3

Hva skjedde: Nettlesere med innebygde agenter som kan handle på brukerens vegne ble gjennom 2025 vist å være sårbare for at en besøkt nettside instruerer agenten til å hente ut data fra andre faner der brukeren er innlogget. Brave publiserte tidlig analyser av angrepsklassen.

Mekanisme: Agenten har brukerens innloggede økt (privat data), leser vilkårlige nettsider (uklarert innhold) og kan sende forespørsler (utgang). Full triade i normal bruk.

Konsekvens: Flere rettelser og begrensninger; angrepsklassen anses ikke som løst.

Lærdom: Dette er triaden i sin mest ubehagelige form, fordi den oppstår av produktets grunnidé og ikke av en konfigurasjonsfeil.

Diskusjon: Kan en agentisk nettleser gjøres trygg uten å miste poenget sitt?

Kilde: Braves sikkerhetsblogg (2025) og etterfølgende forskning.

21. GTG-1002: KI-orkestrert spionasje

2025 · Anthropic · Mønster: 3

Hva skjedde: Anthropic rapporterte 14. november 2025 at de hadde avdekket og stanset det de beskrev som den første dokumenterte storskala cyberspionasjekampanjen orkestrert av KI. En gruppe knyttet til kinesiske statlige aktører, betegnet GTG-1002, brukte Claude Code koblet gjennom MCP-tjenere til rekognosering, kartlegging, testing av legitimasjon og dataauthenting mot rundt tretti mål: teknologiselskaper, finansinstitusjoner, kjemisk industri og offentlige etater. Operatørene omgikk sikkerhetsmekanismene ved å framstille arbeidet som lovlig sikkerhetstesting. Anthropic anslo at modellen utførte 80–90 prosent av operasjonen selvstendig.

Mekanisme: Misbruk gjennom rollespill, ikke modellinitiativ. Menneskene var godkjennerne ved kontrollpunkter, ikke operatører steg for steg.

Konsekvens: Kontoer stengt, mål varslet, rapport publisert. Kampanjen er registrert som C0062 i MITRE ATT&CK.

Lærdom: Vendepunktet er ikke at KI kan brukes i angrep — det er autonomigraden. Merk at framstillingen er Anthropics egen og ikke uavhengig verifisert.

Diskusjon: Hvilke deler av rapporten ville du helst hatt bekreftet fra uavhengig hold?

Kilde: Anthropic, «Disrupting the first reported AI-orchestrated cyber espionage campaign» (november 2025); MITRE ATT&CK C0062.

22. Sårbarheter i MCP-infrastruktur

2025–2026 · Økosystemet · Mønster: 3

Hva skjedde: Model Context Protocol gjorde det enkelt å koble agenter til verktøy — og dermed enkelt å koble dem til noe usikkert. Det er rapportert alvorlige sårbarheter i mye brukt MCP-infrastruktur, blant annet fjernkjøring av kode (CVE-2025-6514, CVSS 9,6) og injeksjon via kroker i et utbredt kodeverktøy (CVE-2025-59536, CVSS 8,7).

Mekanisme: Agenten arver sikkerhetsnivået til den svakeste tjeneren den er koblet til.

Konsekvens: Rettelser; økende bevissthet om at verktøykjeden er angrepsflate.

Lærdom: Behandle MCP-tjenere som avhengigheter i forsyningskjeden: pin versjoner, vurder leverandør, begrens rettigheter.

Diskusjon: Hvor mange MCP-tjenere er koblet til agentene dine, og hvem vedlikeholder dem?

Kilde: Offentlige CVE-oppføringer; sikkerhetsrapporter 2025–2026.

23. Slack AI og delte kanaler

2024 · Salesforce/Slack · Mønster: 3

Hva skjedde: Forskere viste at innhold plassert i en offentlig kanal kunne påvirke Slacks KI-funksjon til å lekke informasjon fra private kanaler brukeren hadde tilgang til, gjennom instruksjoner i teksten den hentet inn.

Mekanisme: Indirekte injeksjon der «uklarert innhold» var interne, men lavt betrodde kanaler.

Konsekvens: Rettelser og begrensninger.

Lærdom: «Uklart innhold» betyr ikke nødvendigvis eksternt. Alt som noen kan skrive inn i, teller — også interne systemer.

Diskusjon: Hvilke interne kilder i deres organisasjon bør regnes som uklart innhold?

Kilde: PromptArmor (august 2024); Slacks respons.

24. Air Canada og sorgrabatten

2024 · Air Canada · Mønster: 4

Hva skjedde: Jake Moffatt spurte Air Canadas chatbot om sorgrabatt etter et dødsfall i familien. Boten opplyste at han kunne kjøpe billett til full pris og søke om rabatt innen 90 dager. Det var ikke selskapets policy. Moffatt kjøpte billetter for 1 630,36 kanadiske dollar og fikk avslag på søknaden. Air Canada argumenterte for British Columbia Civil Resolution Tribunal blant annet med at chatboten var «en separat juridisk enhet som er ansvarlig for sine egne handlinger».

Mekanisme: Konfabulering koblet direkte til en forpliktelse for virksomheten.

Konsekvens: Tribunalet avviste argumentet i februar 2024, fant uaktsom feilinformasjon, og tilkjente 650,88 kanadiske dollar pluss renter og gebyrer — i alt rundt 812 dollar.

Lærdom: Beløpet er lite, prinsippet stort: argumentet om at boten er sin egen ansvarlige aktør ble prøvd og forkastet. Setter du en agent til å snakke for virksomheten, snakker virksomheten.

Diskusjon: Hva ville konsekvensene vært om Air Canada hadde vunnet fram?

Kilde: Moffatt v. Air Canada, 2024 BCCRT 149.

25. Cursors oppdiktede lisensregel

2025 · Anysphere (Cursor) · Mønster: 4

Hva skjedde: I april 2025 svarte støtteboten for kodeverktøyet Cursor at produktet hadde innført en regel om at abonnementet bare kunne brukes på én maskin. Regelen fantes ikke. Brukere som trodde selskapet hadde strammet inn, sa opp abonnementene i protest og skrev om det offentlig. Selskapet måtte forklare at boten hadde funnet på det.

Mekanisme: Konfabulering om egen produktpolicy, formidlet med samme autoritet som ekte informasjon.

Konsekvens: Oppsigelser og tillitstap. Ingen rettssak, men trolig dyrere enn Air Canada-saken.

Lærdom: Boten trenger ikke å love noe for å koste penger. Det holder at den beskriver en policy feil.

Diskusjon: Hvordan snevrer du inn svarrommet for spørsmål om vilkår og priser?

Kilde: Bred dekning og selskapets egne uttalelser, april 2025.

26. DPD-boten som skrev dikt om arbeidsgiveren

2024 · DPD · Mønster: 3, 4

Hva skjedde: En frustrert kunde klarte i januar 2024 å få leveringsselskapet DPDs chatbot til å banne, kalle seg verdens verste leveringstjeneste og skrive et nedsettende dikt om DPD. Skjermbildene spredte seg raskt. Selskapet slo av funksjonen og viste til en systemoppdatering.

Mekanisme: Direkte prompt injection. Teknisk trivielt.

Konsekvens: Omdømme. Ingen økonomisk skade utover det.

Lærdom: Egner seg godt tidlig i undervisningen: morsom, ufarlig og viser mekanismen helt tydelig før alvorret introduseres.

Diskusjon: Hva er det verste en bot i deres navn kan si, og hva hindrer det i dag?

Kilde: Bred dekning januar 2024; DPDs uttalelse.

27. NYC MyCity

2024 · New York City · Mønster: 4

Hva skjedde: Byens chatbot for småbedrifter ga i flere tilfeller råd som ville innebåret lovbrudd — blant annet at arbeidsgivere kunne ta av ansattes tips og at utleiere kunne nekte leietakere med boligstøtte. Byen valgte å beholde tjenesten med tydeligere advarsler i stedet for å ta den ned.

Mekanisme: Konfabulering på et rettsområde der plausibelt og riktig ligger nær hverandre.

Konsekvens: Kritikk; tjenesten fortsatte i justert form.

Lærdom: Interessant fordi beslutningen ikke er opplagt. En offentlig etat måtte veie nytte mot risiko uten et rent svar.

Diskusjon: Ville du beholdt tjenesten? Begrunn med alvorlighetstrappen i modul 5.4.

Kilde: The Markup / The City, mars 2024; byens uttalelser.

28. AI Overviews og limet på pizzaen

2024 · Google · Mønster: 4, 5

Hva skjedde: Da Google rullet ut KI-genererte sammendrag i søk, foreslo funksjonen blant annet å tilsette lim i pizzasaus for å få osten til å feste seg, og at man burde spise steiner. Rådene stammet fra satire og spøkefulle innlegg som ble gjengitt uten kontekst.

Mekanisme: Konfabulering ganget med skala. Feilraten var lav, men Google-søk er milliarder av spørringer.

Konsekvens: Betydelig omtale; funksjonen ble innskrenket for enkelte spørsmålstyper.

Lærdom: Illustrerer skalapoenget bedre enn nesten noe annet: en sjelden feil i verdens mest brukte grensesnitt er en daglig hendelse.

Diskusjon: Ved hvilken feilrate er det forsvarlig å rulle ut noe til én milliard brukere?

Kilde: Bred dekning mai 2024; Googles blogginnlegg om justeringene.

29. Mata mot Avianca

2023 · Advokat i New York · Mønster: 4

Hva skjedde: En advokat leverte et rettsdokument der flere siterte dommer ikke eksisterte; de var generert av ChatGPT. Advokaten hadde spurt modellen om sakene var ekte, og modellen bekreftet det. Retten ila sanksjoner.

Mekanisme: Konfabulering med perfekt format. Oppdiktete saksreferanser ser ut som saksreferanser.

Konsekvens: Sanksjoner og betydelig oppmerksomhet i juridiske miljøer internasjonalt.

Lærdom: Kontrollspørsmålet «er dette ekte?» stilt til samme modell er ingen kontroll.

Diskusjon: Hva er den minste endringen i arbeidsflyten som ville fanget dette?

Kilde: Mata v. Avianca, Inc., S.D.N.Y. (2023).

30. Deloitte Australia

2025 · Deloitte · Mønster: 4, 7

Hva skjedde: En rapport levert til australske myndigheter viste seg å inneholde kilder og henvisninger som ikke eksisterte. Selskapet måtte tilbakebetale deler av honoraret.

Mekanisme: Samme som Mata-saken, i profesjonell rådgivning i stedet for jus.

Konsekvens: Delvis tilbakebetaling; omdømmehendelse for et selskap som selger kvalitetssikring.

Lærdom: To år etter Mata-saken, med full kjennskap til problemet, skjedde det igjen hos en organisasjon med formelle kvalitetsrutiner. Kunnskap om risikoen er ikke et tiltak.

Diskusjon: Hvorfor fanget ikke kvalitetssikringen dette?

Kilde: Australsk statsforvaltnings redegjørelse og Deloittes uttalelser, oktober 2025.

31. Apple Intelligence og nyhetsvarslene

2025 · Apple · Mønster: 4

Hva skjedde: Apples KI-funksjon for å sammenfatte varsler produserte feilaktige nyhetssammendrag under mediehusenes logoer, blant annet et sammendrag som feilaktig meldte om utfallet i en høyprofilert sak, tilskrevet BBC. BBC klaget. Apple begrenset funksjonen for nyhetsvarsler.

Mekanisme: Komprimering er konfabuleringens gunstigste vilkår — å presse en artikkel til én linje krever valg modellen ikke har grunnlag for.

Konsekvens: Funksjonen ble trukket tilbake for nyhetskategorien.

Lærdom: Feilen fikk et annet merkenavn på seg. Når KI-en din siterer andre, låner du deres troverdighet og risikerer den.

Diskusjon: Hvem eier feilen når Apples modell feilsiterer BBC?

Kilde: BBCs klage og Apples uttalelser, januar 2025.

32. Bard-demonstrasjonen

2023 · Google · Mønster: 4, 7

Hva skjedde: I Googles egen lanseringsannonse for Bard svarte modellen at James Webb-teleskopet tok det første bildet av en planet utenfor vårt solsystem. Det var feil. Feilen ble oppdaget av astronomer i annonsematerialet, ikke internt.

Mekanisme: Konfabulering — i markedsføringsmateriell som hadde vært gjennom flere ledd.

Konsekvens: Betydelig fall i Alphabets aksjekurs i dagene etter, i medieomtalen anslått til rundt 100 milliarder dollar i markedsverdi. Sammenhengen mellom feilen og kursfallet er ikke entydig etablert.

Lærdom: Organisatorisk: ingen faktasjekket selskapets eget flaggskipeksempel.

Diskusjon: Hvordan kunne dette passere gjennom en lanseringsprosess?

Kilde: Googles annonsemateriell februar 2023; samtidig dekning.

33. CNET og Sports Illustrated

2023 · Red Ventures / Arena Group · Mønster: 4, 7

Hva skjedde: Teknologinettstedet CNET publiserte KI-genererte økonomiartikler med faktafeil, uten tydelig merking. Senere samme år ble Sports Illustrated avslørt for å publisere KI-genererte artikler under oppdiktete forfatternavn med KI-genererte portrettbilder.

Mekanisme: Konfabulering kombinert med bevisst skjuling av produksjonsmåten.

Konsekvens: Rettelser, redaksjonelle opprydninger, ledelsesendringer og betydelig tillitstap.

Lærdom: Det som ødela sakene var ikke KI-bruken, men at den ble skjult. Åpenhetsplikten i KI-forordningens artikkel 50 adresserer nettopp dette.

Diskusjon: Hvor går grensen for når KI-bruk må opplyses?

Kilde: Futurism, januar og november 2023; selskapenes uttalelser.

Del E: Skala og hastighet

34. Robodebt

2016–2020 · Australske myndigheter · Mønster: 5, 7

Hva skjedde: Et automatisert system sammenlignet inntekt oppgitt til skattemyndighetene med utbetalte trygdeytelser, og sendte krav om tilbakebetaling ved avvik. Metoden fordelte årsinntekt jevnt utover året, noe som ga systematisk feil for alle med uregelmessig arbeid. Bevisbyrden ble snudd: mottakeren måtte dokumentere at kravet var feil. Hundretusener fikk krav, mange uriktige.

Mekanisme: En metodisk feil ganget med full automatisering, uten mekanisme for å oppdage feilen ovenfra.

Konsekvens: En kongelig granskningskommisjon konkluderte skarpt i 2023, ordningen ble kjent ulovlig, og staten betalte tilbake milliardbeløp. Kommisjonen dokumenterte at juridiske advarsler internt var ignorert.

Lærdom: Ingen KI involvert. Systemets utdata ble behandlet som bevis i stedet for hypotese. Advarslene kom, og de ble avvist.

Diskusjon: Hvilken enkelt endring i saksbehandlingen ville forhindre det meste av skaden?

Kilde: Royal Commission into the Robodebt Scheme, sluttrapport 2023.

35. Toeslagenaffaire

ca. 2013–2021 · Nederlandske skattemyndigheter · Mønster: 5, 7

Hva skjedde: Et risikoklassifiseringssystem for å oppdage svindel med barnepassstøtte vektet blant annet dobbelt statsborgerskap. Tusenvis av familier, uforholdsmessig mange med minoritetsbakgrunn, ble uriktig anklaget for svindel og avkrevd store tilbakebetalinger. Mange ble økonomisk ruinert; over tusen barn ble plassert utenfor hjemmet.

Mekanisme: Diskriminerende variabel i et automatisert system, kombinert med at utfallet ble behandlet som konklusjon.

Konsekvens: Hele den nederlandske regjeringen gikk av i januar 2021. Omfattende erstatningsordninger.

Lærdom: Den alvorligste dokumenterte konsekvensen av algoritmisk forvaltning i Europa. Bakgrunnen for hvorfor KI-forordningen klassifiserer offentlige ytelsessystemer som høy risiko.

Diskusjon: Hvorfor tok det åtte år før dette ble stanset?

Kilde: Nederlandsk parlamentarisk granskning (2020); Autoriteit Persoonsgegevens' vedtak.

36. Post Office Horizon

1999–2015 · British Post Office · Mønster: 5, 7

Hva skjedde: Regnskapssystemet Horizon viste underskudd på postkontorer der det ikke var noe underskudd. Over 900 postkontorbestyrere ble straffeforfulgt for tyveri og underslag. Noen ble fengslet. Flere tok sitt eget liv. Feilen lå

i programvaren, og Post Office kjente til feilene mens rettssakene pågikk.

Mekanisme: Ikke KI. Ren systemtillit: maskinens tall ble regnet som sannere enn hundrevis av menneskers samstemte forklaringer.

Konsekvens: Dommer omgjort ved lov, offentlig granskning, omfattende erstatninger. Regnes som en av Storbritannias største rettssikkerhetsskandaler.

Lærdom: Obligatorisk i dette emnet nettopp fordi ingen KI var involvert. Mønsteret er eldre enn teknologien; KI gjør det billigere å gjenta.

Diskusjon: Hva skulle til for at én bestyrers forklaring ble trodd mot systemet?

Kilde: Post Office Horizon IT Inquiry; Bates m.fl. mot Post Office Ltd (2019).

37. Apple Card og kredittgrensene

2019 · Goldman Sachs / Apple · Mønster: 5

Hva skjedde: Flere ektepar med felles økonomi rapporterte at mannen fikk vesentlig høyere kredittgrense enn kvinnen. Saken startet med en viral melding fra utvikleren David Heinemeier Hansson. New Yorks finanstilsyn gransket saken og fant ikke grunnlag for å konstatere ulovlig forskjellsbehandling, men kritiserte at kundeservice ikke kunne forklare avgjørelsene.

Mekanisme: Uforklarlige automatiske avgjørelser i en tjeneste med rettslig betydning for kunden.

Konsekvens: Tilsynssak, omdømmehendelse, ingen sanksjon for diskriminering.

Lærdom: Selv når systemet ikke er ulovlig, er «ingen kan forklare hvorfor» i seg selv et alvorlig problem. Sentralt for GDPR artikkel 22.

Diskusjon: Hva er en tilstrekkelig forklaring på en automatisk kredittavgjørelse?

Kilde: New York State Department of Financial Services, rapport 2021.

38. iTutorGroup

2023 · iTutorGroup · Mønster: 5

Hva skjedde: Selskapets programvare for rekruttering av nettlærere avviste automatisk kvinnelige søkere over 55 år og mannlige søkere over 60. Det amerikanske likestillingsorganet EEOC tok saken, og selskapet inngikk forlik på 365 000 dollar.

Mekanisme: Direkte diskriminerende regel i automatisert utvelgelse.

Konsekvens: Forlik; ansett som en tidlig prinsippsak for tilsynsmyndighetenes håndtering av rekrutteringsalgoritmer.

Lærdom: Ikke maskinlæring — en kodet regel. Viser at «algoritmisk diskriminering» ofte er banal, ikke mystisk.

Diskusjon: Ville en menneskelig rekrutterer med samme regel blitt oppdaget tidligere eller senere?

Kilde: EEOC v. iTutorGroup, forlik august 2023.

Del F: Kontekstskifte og den fysiske verden

39. Tay

2016 · Microsoft · Mønster: 1, 6

Hva skjedde: Microsoft lanserte chatboten Tay på Twitter, trent til å lære av samtaler med brukere. Innen et døgn hadde koordinerte grupper lært den å produsere rasistisk og nazistisk innhold. Microsoft slo den av.

Mekanisme: Systemet fungerte som spesifisert — det lærte av brukerne. Ingen hadde spesifisert hva som skjer når brukerne er fiendtlige og organiserte.

Konsekvens: Tjenesten avviklet innen 24 timer; internasjonal omtale.

Lærdom: Den reneste illustrasjonen som finnes på at testmiljøet ditt ikke er internett. Ti år gammel og fortsatt den beste innledningen til temaet motstandere.

Diskusjon: Hvilken test ville avdekket dette før lansering?

Kilde: Microsofts egen redegjørelse, mars 2016.

40. Uber ATG i Tempe

2018 · Uber Advanced Technologies Group · Mønster: 6, 7

Hva skjedde: En selvkjørende testbil traff og drepte Elaine Herzberg, som trillet en sykkel over veien utenfor et fotgjengerfelt. Havarikommisjonen NTSB fant flere lag av svikt: klassifiseringssystemet vekslet mellom å tolke objektet som ukjent, kjøretøy og sykkel, og hver omklassifisering nullstilte sporingen av bevegelsesbanen; nødbremsefunksjonen var deaktivert under testkjøring for å unngå ubehagelig kjøring; systemet var ikke bygget for å forutse fotgjengere utenfor fotgjengerfelt; sikkerhetssjåføren så på telefonen.

Mekanisme: Kontekstskifte kombinert med automasjonsparadokset i sin mest bokstavelige form.

Konsekvens: Dødsfall. Uber avviklet testingen i Arizona. Sikkerhetssjåføren ble senere dømt for uaktsomhet.

Lærdom: Fire barrierer sviktet samtidig. Sveitserostmodellen i praksis. Merk særlig at nødbremsen var slått av av komfortgrunner.

Diskusjon: Hvem bar ansvaret, og hvordan fordeler du det mellom sjåfør, selskap og myndighet?

Kilde: NTSB Highway Accident Report HAR-19/03 (2019).

41. Cruise i San Francisco

2023 · Cruise / General Motors · Mønster: 6, 7

Hva skjedde: 2. oktober 2023 ble en fotgjenger påkjørt av en bilist som stakk fra stedet, og kastet inn i banen til en førerløs Cruise-taxi. Bilen bremsset, men traff henne. Deretter utførte den sin programmerte manøver etter kollisjon: den kjørte til siden for å stanse trygt — med kvinnen under bilen. Hun ble dratt rundt seks meter i om lag 11 km/t.

Mekanisme: Systemet hadde ingen representasjon av tilstanden «det ligger et menneske under meg». Manøveren var riktig for alle scenarioene den var designet for.

Konsekvens: Alvorlig personskade. Se også case 44 for den organisatoriske delen.

Lærdom: Kontekstskifte i renest form: en fornuftig regel anvendt på en situasjon ingen hadde modellert.

Diskusjon: Hvor mange slike umodellerte tilstander finnes i et system du kjenner?

Kilde: California DMV, suspensjonsvedtak 24. oktober 2023; NHTSAs forliksavtale.

42. McDonald's og drive-thru

2024 · McDonald's og IBM · Mønster: 6

Hva skjedde: Etter tre års utprøving avsluttet McDonald's samarbeidet med IBM om KI-basert bestilling i drive-thru. Videoer av systemet som la til 260 kyllingnuggets på én ordre, eller la bacon på en isdessert, spredte seg bredt.

Mekanisme: Talegjenkjenning og intensjonstolkning i et støyende, uforutsigbart miljø med aksenter, bakgrunnsstøy og folk som ombestemmer seg.

Konsekvens: Samarbeidet avsluttet; McDonald's uttalte at de fortsatt vurderte teknologien.

Lærdom: Ikke alle feil er dramatiske. Noen er bare pinlige og dyre nok til at prosjektet dør. Verdifull motvekt til de alvorlige casene.

Diskusjon: Hva var det egentlige problemet — teknologien eller forventningene?

Kilde: McDonald's melding til franchisetakere, juni 2024.

43. Tesla og førerassistanse

2023–2024 · Tesla · Mønster: 6

Hva skjedde: Etter en flerårig granskning av kollisjoner der Autopilot var aktiv, gjennomførte Tesla i desember 2023 en tilbakekalling som omfattet over to millioner kjøretøy i USA. Tiltaket var en programvareoppdatering som skjerpet kontrollen av førerens oppmerksomhet. NHTSA åpnet senere en ny undersøkelse av om oppdateringen var tilstrekkelig.

Mekanisme: Automasjonsparadokset i stor skala: et system godt nok til at føreren slutter å følge med, men ikke godt nok til å klare seg uten.

Konsekvens: Største tilbakekalling knyttet til førerassistanse hittil; pågående tilsynsoppfølging.

Lærdom: Nivå 2-autonomi er den vanskeligste plassen å være: for god til å bli overvåket, for dårlig til å stå alene.

Diskusjon: Er delvis autonomi farligere enn både lavere og høyere nivåer?

Kilde: NHTSA Recall 23V-838 (desember 2023) og etterfølgende undersøkelser.

Del G: Organisatorisk svikt

44. Cruise og videoen som ikke ble vist

2023 · Cruise · Mønster: 7

Hva skjedde: Da Cruise viste opptak av ulykken i case 41 til California DMV dagen etter, ble den delen som viste stoppemanøveren og slepingen ikke vist. DMV suspenderte selskapets tillatelser 24. oktober 2023 og begrunnet det med at Cruise hadde gitt uriktig framstilling av kjøretøyenes sikkerhet.

Mekanisme: Organisatorisk svikt uavhengig av teknologien.

Konsekvens: NHTSA ila 1,5 millioner dollar i gebyr for mangelfull rapportering. Selskapets leder gikk av, virksomheten ble kraftig nedskalert, og GM avviklet til slutt robotaxisatsingen.

Lærdom: Selve kollisjonen var i utgangspunktet ikke selskapets skyld. Håndteringen var. Teknologien overlevde ikke organisasjonens respons.

Diskusjon: Sammenlign case 41 og 44. Hvilken av dem ville du undervist først, og hvorfor?

Kilde: California DMV, vedtak oktober 2023; NHTSA consent order.

45. Grok: systeminstruksen som endret alt

2025 · xAI · Mønster: 7

Hva skjedde: I mai 2025 begynte Grok å trekke inn påstander om «hvitt folkemord» i Sør-Afrika i svar på urelaterte spørsmål, inkludert spørsmål om baseball. xAI forklarte det med en uautorisert endring i systeminstruksen. I juli produserte boten antisemittisk innhold, roste Hitler og omtalte seg selv som «MechaHitler». xAIs forklaring var at en endring lenger oppe i kodekjeden hadde reaktivert utdaterte systeminstruksjoner, blant annet en instruks om ikke å vike unna politisk ukorrekte påstander, og at boten dermed ble mottakelig for ekstremt innhold i innleggene den svarte på. Selskapet slettet innleggene, begrenset funksjonaliteten midlertidig og beklaget offentlig 12. juli.

Mekanisme: En tekstfil ble endret. Ingen kontroll fanget det. Det tok timer før noen oppdaget det.

Konsekvens: Betydelig omdømmehendelse; henvendelser fra amerikanske folkevalgte.

Lærdom: Systeminstruksen er produksjonskode og må gjennom versjonskontroll, gjennomgang, testing og gradvis utrulling. Merk også at forklaringene er selskapets egne.

Diskusjon: Hvilke kontroller ville du innført for filer som styrer en agents atferd?

Kilde: xAIs offentlige redegjørelser mai og juli 2025; brev til amerikanske kongressmedlemmer.

46. Gemini og bildegenereringen

2024 · Google · Mønster: 1, 7

Hva skjedde: Googles bildegenerator produserte historisk misvisende bilder — blant annet etnisk mangfoldige framstillinger av tyske soldater fra 1943 — som følge av en mekanisme som skulle motvirke skjevhet ved å variere

framstillingen av mennesker. Mekanismen ble anvendt også der historisk nøyaktighet var poenget. Google stanset funksjonen for bilder av mennesker.

Mekanisme: Et tiltak mot ett problem (ensidig representasjon) ble anvendt uten unntak, og skapte et annet.

Konsekvens: Funksjonen stengt i flere måneder; betydelig kritikk fra flere politiske hold samtidig.

Lærdom: Korrigeringer for skjevhet er selv spesifikasjoner, og kan selv svikte. Nyttig case for å vise at «ansvarlig KI» ikke er en retning man beveger seg i, men en avveining.

Diskusjon: Hvordan ville du spesifisert regelen slik at både 1943 og «en gruppe leger» blir riktig?

Kilde: Googles blogginnlegg februar 2024.

47. Klarna reverserer

2024–2025 · Klarna · Mønster: 7

Hva skjedde: Klarna erstattet i 2024 store deler av kundeservicen med KI og kommuniserte høylytt at systemet gjorde arbeidet til rundt 700 heltidsansatte. I 2025 justerte selskapet kursen og begynte å ansette mennesker igjen, med begrunnelsen at kvaliteten hadde falt for mye.

Mekanisme: Ikke en teknisk svikt. En strategisk beslutning tatt for raskt, og deretter korrigert.

Konsekvens: Delvis reversering; mye omtalt som korrektiv til automatiseringsoptimisme.

Lærdom: Å reversere er en legitim beslutning og blir billigere jo tidligere den tas. Nyttig case fordi den ikke handler om katastrofe, men om vurdering.

Diskusjon: Hvilke måltall burde selskapet fulgt for å oppdaget kvalitetsfallet tidligere?

Kilde: Klarnas egne uttalelser og kvartalsrapportering 2024–2025.

48. Samsung og kildekoden i chatboten

2023 · Samsung · Mønster: 7

Hva skjedde: Ansatte ved Samsungs halvlederdivisjon limte intern kildekode og møtereferater inn i ChatGPT for å få hjelp med feilsøking og oppsummering. Selskapet innførte kort tid etter forbud mot bruk av eksterne KI-tjenester på arbeidsutstyr.

Mekanisme: Ingen teknisk feil. Fravær av retningslinjer før verktøyet var i bruk.

Konsekvens: Interne restriksjoner; casen er blitt standardeksempelet på skygge-KI.

Lærdom: De ansatte gjorde ikke noe galt etter reglene som fantes, fordi det ikke fantes regler. Første punkt i enhver KI-styring er å vite hva som allerede er i bruk.

Diskusjon: Hva er sannsynligheten for at noe tilsvarende skjer der du jobber eller studerer i dag?

Kilde: Bloomberg og koreanske medier, april–mai 2023.

Oversiktstabell: case etter sviktmønster

Mønster	Caser
1 Spesifikasjonssvikt	2, 3, 4, 5, 6, 7, 8, 14, 15, 39, 46
2 Agentisk feilhandling	2, 4, 10, 11, 12, 13, 14, 15
3 Kapring	16, 17, 18, 19, 20, 21, 22, 23, 26
4 Konfabulering	24, 25, 26, 27, 28, 29, 30, 31, 32, 33
5 Skala og hastighet	6, 7, 8, 9, 28, 34, 35, 36, 37, 38
6 Kontekstskifte	2, 13, 39, 40, 41, 42, 43
7 Organisatorisk svikt	9, 15, 18, 30, 32, 33, 34, 35, 36, 40, 41, 44, 45, 46, 47, 48

Ti caser hvis du bare har én time

1, 15, 16, 17, 24, 34, 36, 39, 41, 45.

Denne rekken tar deg gjennom hype, agentisk svikt, kapring, juridisk ansvar, forvaltningsskandale, systemtillit, motstandere, fysisk skade og organisatorisk svikt — hele emnet i komprimert form.